UJI KEMIRIPAN KALIMAT MENGGUNAKAN FUNGSI TERBILANG PADA *PRE-PROCESSING* DAN *COSINE SIMILARITY* DALAM BAHASA INDONESIA

SENTENCES SIMILARITY TEST USING COUNTABLE FUNCTION ON PRE-PROCESSING AND COSINE IN INDONESIAN

Ardi Sanjaya[1)], **Sempu Dwi Sasongko**[2)]

[1)] *Program Studi Teknik Informatika, Fakultas Teknik, Universitas Nusantara PGRI Kediri*
[2)] *Program Studi Pendidikan Bahasa dan Sastra Indonesia, Fakultas Keguruan dan Ilmu Kependidikan, Universitas Nusantara PGRI Kediri*
Jl KH Ahmad Dahlan 76 Mojoroto Kediri
Email : dersky@gmail.com[1)], *sempu@unpkediri.ac.id*[2)]

Abstrak

Proses stopword/filtering pada pre-processing di beberapa penelitian terdahulu cenderung membuang kata yang dianggap tidak perlu, termasuk angka dan beberapa tanda baca. Berdasarkan pengamatan peneliti, kalimat yang diuji atau dibandingkan terkadang terdari atas susunan kompleks berupa kata, angka dan tanda baca. Penelitian ini bertujuan untuk meningkatkan atau optimasi kinerja uji kemiripan kalimat berbahasa Indonesia dengan menambahkan fungsi terbilang pada pre-processing. Pada tahap pre-processing, setiap kata akan dideteksi apabila terdapat unsur angka baik itu bulat atau pecahan desimal maka akan dikonversi menjadi bentuk teks atau kata. Beberapa tanda baca seperti tanda persen juga diubah ke bentuk teks. Uji kemiripan kalimat menggunakan cosine similarity. Pengujian menggunakan data yang telah dipastikan susunannya kompleks namun memiliki kemiripan yang mendekati oleh pakar terkait. Pada pengujian juga dilakukan perbandingkan antara pre-processing yang menggunakan fungsi terbilang dan yang tidak. Berdasarkan hasil pengujian, didapati 12 pengujian dari 13 pengujian (92,30%) memiliki peningkatan nilai kemiripan dibandingkan pada pre-processing yang tidak menggunakan fungsi terbilang. Nilai kemiripan tergantung pada susunan masing-masing kalimat yang diuji.

Kata kunci: *Cosine Similarity, Optimasi, Pre-Processing*

Abstract

The stopword/filtering process in pre-processing in several previous studies tends to discard words that are considered unnecessary, including numbers and some punctuation marks. Based on the researcher's observations, the sentences being tested or compared sometimes consist of complex arrangements in the form of words, numbers and punctuation marks. This study aims to improve or optimize the performance of the Indonesian sentence similarity test by adding a spelled function to the pre-processing. At the pre-processing stage, each word will be detected if there is an element of a number, be it a whole or a decimal fraction, it will be converted into text or word form. Some punctuation marks such as the percent sign are also converted to text. Sentence similarity test using cosine similarity. The test uses data that has been confirmed to have a complex arrangement but has a close resemblance by the relevant expert. In the test, a comparison is also made between the pre-processing that uses the calculated function and the one that does not. Based on the test results, it was found that 12 out of 13 tests (92.30%) had an increase in the similarity value compared to pre-processing that did not use the count function. The similarity value depends on the arrangement of each sentence being tested.

Keywords : *Cosine Similarity, Optimization, Pre-Processing*

1. PENDAHULUAN

Pemrosesan Bahasa Alami atau Natural Language Processing (NLP) pada masa sekarang berkembang sangat pesat untuk membantu interaksi manusia dan komputer. Salah satunya banyak diimplementasikan dalam bidang *text mining*. Misalnya membantu dalam menentukan kemiripan suatu dokumen teks berdasarkan ciri-ciri tertentu. Sudah banyak penelitian yang meneliti pemrosesan teks dengan menggunakan algoritma *pre-processing* dan penguji kemiripan teks atau dokumen [1][2]. Namun, tidak semua algoritma *pre-processing* terutama *stopword/filtering* yang lazim digunakan bisa sesuai dengan data atau teks yang akan diolah. Berdasarkan studi literatur

dan pengamatan peneliti, pada proses *filtering* tersebut kebanyakan menerapkan penghapusan tanda baca seperti titik, koma dan sejenisnya serta angka [3][4][5]. Dan pada pengujiannya juga jarang yang melibatkan data atau teks yang memiliki unsur penyusun kalimat kompleks atau kalimat yang memiliki unsur angka atau tanda baca lainnya.

Pada artikel ini, peneliti mencoba mengeksplorasi proses *filtering* tersebut dengan menambahkan beberapa seleksi yang diharapkan bisa mengoptimalkan kinerja pengukuran kemiripan antar kalimat dalam bahasa Indonesia dan menghapus kata-kata yang berhubungan dengan angka seperti kata "satu", "dua" dan sejenisnya. Pada pengujiannya akan melibatkan data uji yang kompleks seperti kalimat yang mengandung unsur angka dan beberapa tanda baca. Proses filtering tersebut diharapkan tidak akan membuang bagian kalimat tertentu dan dapat meningkatkan akurasi nilai kemiripan[2]. Pengukuran kemiripan menggunakan algoritma *Cosine similarity*. Algoritma tersebut dipilih karena sesuai dengan karakteristik data latih ataupun data uji yang telah mengalami *pre-processing* karena masing-masing kata hasil *pre-processing* bisa dianggap sebagai *vector* [6].

2. DASAR TEORI

2.1 Natural Language Processing

Natural Language Processing (NLP) merupakan salah satu cabang ilmu AI yang berfokus pada pengolahan bahasa natural atau bahasa alami. Bahasa natural adalah bahasa yang secara umum digunakan oleh manusia dalam berkomunikasi satu sama lain [7]. NLP dalam arti luas untuk mencakup segala jenis manipulasi komputer terhadap bahasa alami [8]. NLP melakukan proses pembuatan model komputasi dari bahasa, sehingga dapat terjadi suatu interaksi antara manusia dan komputer dengan perantaraan bahasa alami [9].

2.2 Case Folding

Merupakan tahap perubahan huruf dari huruf kapital menjadi huruf kecil [1]. Hanya huruf a sampai z yang diterima. Karakter selain huruf dihilangkan dan dianggap delimiter [10].

2.3 Tokenizing

Tokenizing adalah proses memecah dokumen menjadi kumpulan kata [11]. Tokenization dapat dilakukan dengan menghilangkan tanda baca dan memisahkannya per spasi. Tahapan ini juga menghilangkan karakter-karakter tertentu seperti tanda baca dan mengubah semua token ke bentuk huruf kecil (lower case) [1][3].

2.4 Fungsi Terbilang

Fungsi terbilang merupakan proses untuk mengubah angka menjadi suatu teks.

2.5 Filtering/Stopword

Stopwords removal merupakan proses penghilangan kata tidak penting pada deskripsi melalui pengecekan kata-kata hasil parsing deskripsi apakah termasuk di dalam daftar kata tidak penting (*stoplist*) atau tidak. Jika termasuk didalam *stoplist* maka kata-kata tersebut akan dihapus dari deskripsi sehingga kata-kata yang tersisa di dalam deskripsi dianggap sebagai kata-kata penting atau *keywords* [1][3].

2.6 *Stemming*

Stemming merupakan proses untuk mencari kata dasar [3]. Proses *stemming* bahasa Indonesia adalah proses untuk mengeliminasi sufiks, prefiks, dan konfiks [10][12].

2.7 Cosine Similarity

Cosine Similarity mengukur kemiripan antara dua dokumen atau teks. Pada *Cosine Similarity* dokumen atau teks dianggap sebagai *vector*. Untuk pencocokan teks, nilai dari *vector* A dan B adalah vektor *term-frequency* dari dokumen. Nilai *cosine similarity* berada pada *range* 0-1[13][14][15][16][17].

$$\text{Similarity (dj, q)} = \frac{\sum_{i=l}^{t}(w_{ij}.w_{iq})}{\sqrt{\sum_{i=l}^{t} w_{ij}^2 . \sum_{i=l}^{t} w_{iq}^2}} \quad \text{….. (1)}$$

3. METODOLOGI PENELITIAN

Penelitian dimulai dengan menelaah dan mencermati langkah-langkah pemrosesan alami penilaian kemiripan antar kalimat. Kalimat yang digunakan dalam tahap ini merupakan kalimat berbahasa Indonesia yang mengandung unsur kompleks tambahan berupa angka dan tanda baca. Berikut disajikan 3 contoh dimana masing-masing contoh terdapat 2 kalimat yang memiliki arti sama dalam bahasa Indonesia :

Tabel 1. *Contoh kalimat dengan unsur kompleks*

ID Kalimat	Unsur	Contoh
A1	Angka	Aulia memperoleh IPK tertinggi 4,0
A2	Angka	Nilai IPK yang diperoleh Aulia empat koma nol
B1	Angka dan tanda baca	Tercatat korban meninggal sebanyak 41 orang, tiga ratus rumah mengalami rusak berat dan enam ribu lainnya rusak ringan akibat badai topan yang menerjang wilayah Nevada.
B2	Angka dan tanda baca	Dari data pemerintah setempat, jumlah korban meninggal di wilayah Nevada ada 41 korban tewas, dengan jumlah rumah rusak berat 372, rusak ringan 6.359 rumah.
C1	Angka dan tanda baca	Ayah membeli rumah dengan harga 100.000.000
C2	Angka dan tanda baca	Rumah yang dibeli ayah seharga seratus juta

Berdasarkan contoh-contoh tabel 1, secara pemahaman dalam Bahasa Indonesia kalimat A1 dan kalimat A2 memiliki arti yang sama. Pada tahap *pre-processing*, beberapa bagian dari kalimat akan hilang seperti pada kalimat A1 yaitu unsur angka. Sedangkan pada kalimat A2 tidak begitu mengalami pengurangan unsur penyusun kalimat. Sehingga kalimat A1 dan kalimat A2 setelah mengalami *pre-processing* yang umum digunakan maka akan mempengaruhi sisi arti dalam bahasa Indonesia maupun nilai kemiripannya apabila dihitung menggunakan algoritma *cosine similarity*. Demikian juga contoh kalimat lainnya Kalimat B1 dan kalimat C1, apabila kalimat B1 dan C1 mengalami *pre-processing* yang umum digunakan maka tanda koma dan angka akan hilang. Berdasar uraian singkat diatas, maka peneliti mencoba menambahkan beberapa seleksi dan algoritma agar dalam kasus seperti tabel 1, data dapat diolah secara optimal terutama pada tahap *pre-processing*. Pengoptimalan tersebut berupa penambahan deteksi angka pada kalimat baik itu angka bulat, pecahan desimal atau dalam format nominal uang rupiah dan mengubahnya menjadi teks dengan memanfaatkan fungsi terbilang. Berikut disajikan perbedaan alur *pre-processing* yang umum digunakan dan yang digunakan pada penelitian yang akan dilakukan :

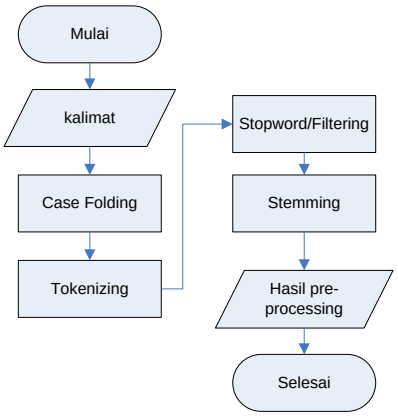

Gambar 1. *Alur Pre-Processing yang umum digunakan*

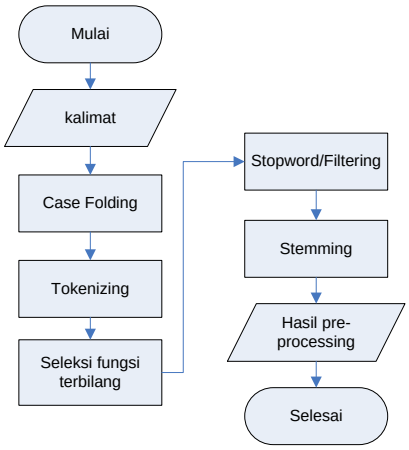

Gambar 2. *Alur Pre-Processing penelitian*

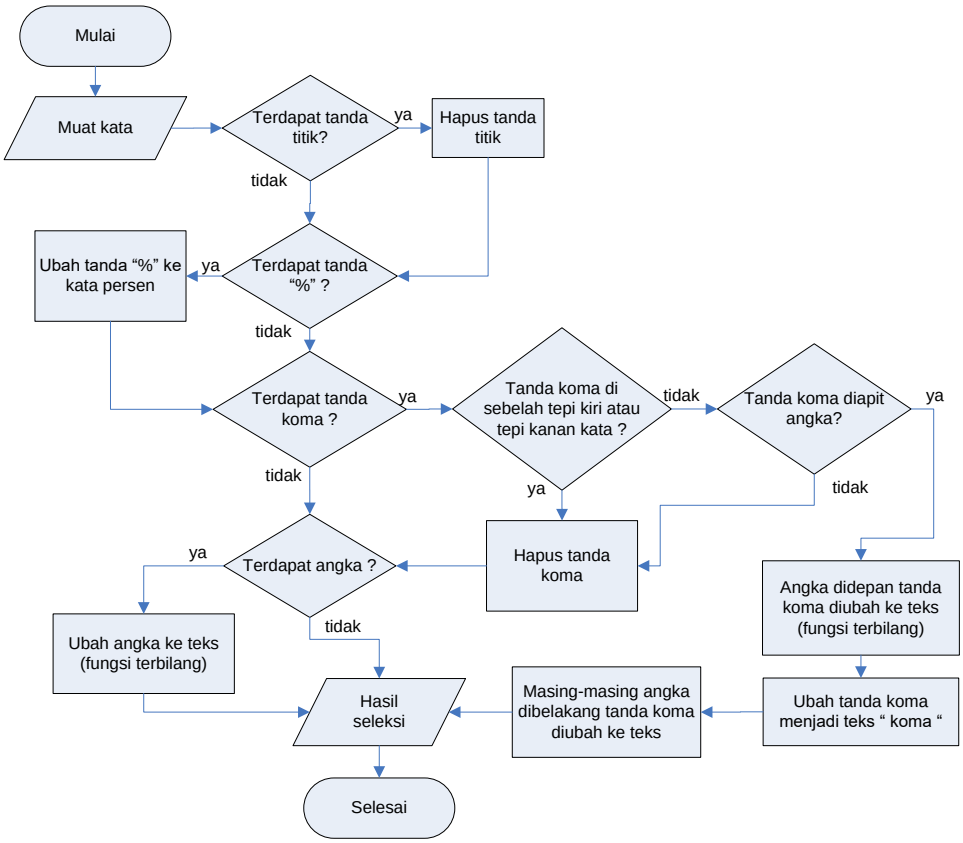

Gambar 3. *Alur proses seleksi dan fungsi terbilang*

Berdasarkan gambar 2, proses seleksi angka dengan memanfaatkan fungsi terbilang pada kalimat untuk kemudian di ubah ke dalam bentuk teks dilakukan setelah proses *tokenizing*. Pada proses seleksi angka, dilakukan pengecekan tanda titik. Apabila terdapat tanda titik maka akan dihapus. Tahapan ini untuk mengantisipasi apabila terdapat angka diatas ribuan yang ditulis dengan pemisah titik pada masing masing tingkatan. Misal terdapat angka 6.359, maka akan berubah menjadi 6359. Proses selanjutnya yaitu pemeriksaan apakah dalam kata ditemukan tanda "%". Apabila ditemukan maka akan diubah ke kata "persen". Kemudian dilanjutkan ke pemeriksaan apakah dalam kata terdapat koma. Jika koma berada di tepi kiri atau kanan maka tanda koma langsung dihapus. Apabila koma berada ditengah kata dan yang mengapitnya adalah angka, maka angka didepan tanda koma dilakukan fungsi terbilang. Sedangkan angka dibelakang koma masing-masing diubah ke teks [18]. Apabila tidak terdapat koma dilanjutkan pengecekan apakah terdapat angka. Apabila terdapat angka maka langsung dilakukan fungsi terbilang. Alur proses seleksi angka dan fungsi terbilang disajikan pada gambar 3 diatas. Untuk skenario pengujian, disajikan seperti pada gambar 4 berikut. Masing-masing kalimat mengalami *pre-processing* yang sama sebelum dilakukan pengukuran nilai kemiripan.

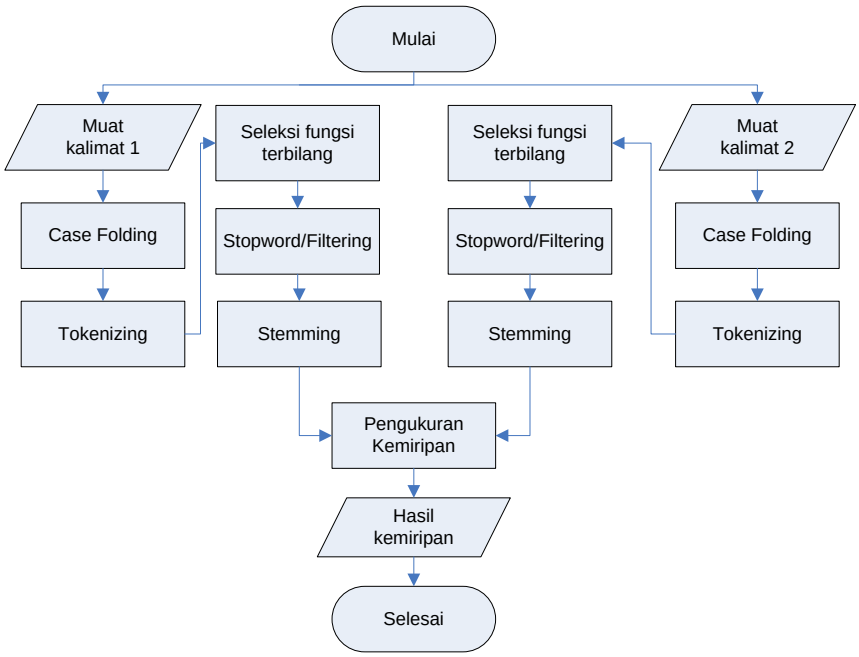

Gambar 4. *Alur proses uji coba*

4. PENGUJIAN DAN PEMBAHASAN

Aplikasi yang digunakan dalam pengujian data ini dibangun menggunakan bahasa pemrograman Python dan liberary pendukung [4][12]. Pengujian pertama dilakukan dengan uji fungsionalitas dan membandingkan dengan alur yang umum digunakan. Data pengujian menggunakan data kalimat seperti pada tabel 1. Hasilnya disajikan pada tabel 2 dan tabel 3 sebagai berikut :

Tabel 2. *Hasil Pengujian Pertama*

ID Kalimat	Kalimat	Hasil *Pre-processing* yang umum digunakan	Hasil *Pre-prcessing* dengan optimasi
A1	Aulia memperoleh IPK tertinggi 4,0	aulia oleh ipk tinggi	aulia oleh ipk tinggi empat koma nol
A2	Nilai IPK yang diperoleh Aulia empat koma nol	nilai ipk oleh aulia koma nol	nilai ipk oleh aulia empat koma nol
B1	Dari data pemerintah setempat, jumlah korban meninggal di wilayah Nevada ada 41 korban tewas, dengan jumlah rumah rusak berat 372, rusak ringan 6.359 rumah.	data perintah tempat korban tinggal wilayah nevada korban tewas rumah rusak berat rusak ringan rumah	data perintah tempat korban tinggal wilayah nevada empat puluh satu korban tewas rumah rusak berat rusak ringan enam ribu tiga ratus lima puluh sembilan rumah
B2	Tercatat korban meninggal sebanyak 41 orang, tiga ratus rumah mengalami rusak berat dan enam ribu lainnya rusak ringan akibat badai topan yang menerjang wilayah Nevada.	catat korban tinggal orang ratus rumah alami rusak berat enam ribu rusak ringan akibat badai topan terjang wilayah nevada	catat korban tinggal empat puluh satu orang tiga ratus rumah alami rusak berat enam ribu rusak ringan akibat badai topan terjang wilayah nevada

ID Kalimat	Kalimat	Hasil *Pre-processing* yang umum digunakan	Hasil *Pre-prcessing* dengan optimasi
C1	Ayah membeli rumah dengan harga 100.000.000	ayah beli rumah harga	ayah beli rumah harga ratus juta
C2	Rumah yang dibeli ayah seharga seratus juta	rumah beli ayah harga ratus juta	rumah beli ayah harga ratus juta

Dari hasil pre-processing pada tabel 2, dapat diketahui bahwa pada kolom hasil *pre-processing* yang umum digunakan ada beberapa kata yang hilang dan pada kolom hasil *pre-processing* dengan optimasi menunjukkan adanya fungsi terbilang yang bekerja.

Tabel 3. *Hasil Pengukuran Nilai Kemiripan (Cosine similarity)*

No	Pengujian Kalimat	Hasil Pre-processing yang umum digunakan (%)	Hasil Pre-prcessing dengan optimasi (%)	Keterangan
1	A1 dan A2	61,24	85,71	Ada peningkatan
2	B1 dan B2	61,90	73,33	Ada peningkatan
3	C1 dan C2	81,65	100	Ada Peningkatan

```
-----
A1 = aulia oleh ipk tinggi
A2 = nilai ipk  oleh aulia  koma nol

Daftar Kata :
['aulia', 'oleh', 'ipk', 'tinggi', 'nilai', 'koma', 'nol']

Vector :
[1, 1, 1, 1, 0, 0, 0]
[1, 1, 1, 0, 1, 1, 1]
Jarak : 0.6123724356957946
Kemiripan : 61.237243569579455
```

Gambar 5. *Screenshot hasil pemrosesan pre-processing tanpa fungsi terbilang*

```
-----
A1 = aulia oleh ipk tinggi empat koma nol
A2 = nilai ipk oleh aulia empat koma nol
Daftar Kata =
['aulia', 'oleh', 'ipk', 'tinggi', 'empat', 'koma', 'nol', 'nilai']
[1, 1, 1, 1, 1, 1, 1, 0]
[1, 1, 1, 0, 1, 1, 1, 1]
Jarak : 0.8571428571428571
Kemiripan : 85.71428571428571
```

Gambar 6. *Screenshot hasil pemrosesan pre-processing menggunakan fungsi terbilang*

Dari Tabel 3, dapat dijelaskan bahwa terdapat peningkatan prosentase kemiripan pada hasil *pre-processing* dengan optimasi dibandingkan dengan hasil *pre-processing* tanpa optimasi. Hal tersebut dikarenakan faktor kata yang tidak terbuang hasil proses fungsi terbilang pada *pre-processing* dan meningkatkan nilai kemiripan saat dihitung nilai kemiripannya.

Tabel 4. *Data Uji Tahap Kedua*

ID Kalimat	Kalimat
D1	Hal ini ditunjukkan melalui pencapaian kuartal kedua profit sebesar Rp 57 miliar dengan total jumlah tertanggung 79.275, dan RBC sebesar 31,66%.
D2	Prestasi pada kuartal ke-2 tahun ini dengan dicapainya profit perusahaan Rp 57 miliar dan RBC kisaran tiga puluh tiga persen

ID Kalimat	Kalimat
E1	Hanya dengan berbelanja produk apa saja (kecuali pembelian pulsa) senilai minimal Rp 75.000, Anda akan mendapat potongan belanja langsung sebesar Rp 65.000 khusus pembayaran dengan BCA KlikPay.
E2	Ayo tingkatkan transaksi di BCA KlikPay. Dapatkan Diskon Rp 65.000 dengan belanja apa saja (kecuali pembelian pulsa) minimal Rp. 75.000
F1	Nilai minimum pemesanan adalah sebesar 5 juta dan maksimum 30 juta dengan tanggal kupon pertama 15 November 2022.
F2	Pertengahan Nopember 2022, XYZ menerapkan batasan pemesanan 5.000.000 sampai dengan 30.000.000
G1	Hari ini kelas 4, 5 dan 6 pulang lebih awal karena guru ada rapat
G2	Dikarenakan ada rapat, anak anak kelas 4 sampai kelas 6 dipulangkan lebih awal
H1	Lagi, tawuran di Cakung melibatkan remaja mengakibatkan 16 orang luka-luka
H2	Belasan orang mengalami luka-luka akibat insiden tawuran antar remaja di Cakung.
I1	Pertandingan sepak bola di Gelora 10 Nopember dibanjiri lebih dari seribu penonton
I2	Sebanyak 1200 orang menyaksikan pertandingan bola di Gelora 10 Nopember Surabaya
J1	7.Petugas gabungan melakukan operasi yustisi dan terjaring 20 lebih orang tidak mematuhi protokol kesehatan karena tidak memakai masker.
J2	Tidak mematuhi protokol kesehatan, puluhan orang terjaring dalam operasi yustisi
K1	Pengeluaran terbesar Formula E saat ini sebesar Rp 560 miliar. Itu dipakai untuk pembayaran commitment fee ke Formula E Operation kata Prasetyo melalui keterangan tertulis.
K2	Prasetyo mengatakan bahwa dana sebesar 560 M digunakan untuk pembayaran commitment fee ke Formula E Operation.
L1	Sekolah membagikan buku pelajaran kepada siswa kelas V
L2	Semua siswa kelas 5 menerima pembagian buku dari sekolah
M1	Kendati demikian, Novie mendapat informasi bahwa ada maskapai yang menunggu periode summer (musim panas) 2022 pada akhir Maret 2022 ini.
M2	"Ada kemungkinan maskapai menunggu periode summer 2022 yang dimulai akhir Maret 2022, belum ada finalnya," tutur Novie

Tabel 5. *Hasil Pengujian Tahap Dua*

Kalimat Uji	Hasil Pre-processing yang umum digunakan (%)	Hasil Pre-prcessing dengan optimasi (%)	Keterangan
D1 dan D2	57,74	66,82	Ada Peningkatan
E1 dan E2	67,08	70,81	Ada Peningkatan
F1 dan F2	12,31	49,03	Ada Peningkatan
G1 dan G2	63,25	65,46	Ada Peningkatan
H1 dan H2	70,71	73,78	Ada Peningkatan
I1 dan I2	53,45	60,30	Ada Peningkatan
J1 dan J2	74,62	78,45	Ada Peningkatan
K1 dan K2	95,41	96,33	Ada Peningkatan
L1 dan L2	77,15	71,43	Penurunan
M1 dan M2	65,47	88,99	Ada Peningkatan

Berdasarkan tabel 5 diatas, dari 10 pengujian terdapat 9 nilai dengan peningkatan nilai kemiripan dan 1 nilai dengan penurunan nilai kemiripan. Pada pengujian kalimat L1 dan L2, didapat nilai pengukuran kemiripan sebesar 71,43%, lebih rendah dibandingkan hasil pre-processing tanpa optimasi sebesar 77,15%. hal tersebut dikarenakan secara susunan ada 1 kata yang menggunakan simbol untuk menyatakan keterangan kelas yaitu "V" yang apabila diterjemahkan menjadi angka 5 (lima). Karena keterbatasan sistem, maka sistem tidak menerjemahkan simbol "V" menjadi huruf "lima". Sehingga nilai kemiripan menjadi menurun bila dibandingkan dengan hasil *pre-processing* tanpa optimasi. Peneliti mencoba mengganti simbol "V" dengan tanda angka "5" dan menjalankan *pre-processing* serta menghitung nilai kemiripan. Didapat nilai kemiripan naik menjadi 85,71%.

Pada 9 pengujian lainnya, nilai kemiripan pada *pre-processing* dengan optimasi dikarenakan adanya susunan kata yang berupa angka yang berhasil dikonversi menjadi teks dengan fungsi terbilang yang mana dapat meningkatkan nilai kemiripan.

5. KESIMPULAN

Berdasarkan pengujian dan analisa yang telah dilakukan, optimasi *pre-processing* dengan menambahkan fungsi terbilang terbukti dapat meningkatkan nilai kemiripan apabila dihitung menggunakan *cosine similarity*. Pada susunan kalimat yang terdapat angka, akan diubah menjadi teks dengan fungsi terbilang dan meningkatkan nilai kemiripan. Dari total 13 data pengujian pada pengujian ke-1 dan ke-2, 12 pengujian atau 92,30% menunjukkan ada peningkatan nilai kemiripan dan 1 pengujian menunjukkan adanya penurunan nilai kemiripan. Hal tersebut dikarenakan keterbatasan sistem yang memang tidak didesain untuk mengkonversi angka dalam format romawi.

Saran untuk penelitian selanjutnya yaitu menambahkan deteksi format angka romawi serta mungkin format-format lainnya dan juga pengujian menggunakan data yang lebih kompleks lagi agar kedepannya sistem pengukur kemiripan kalimat dapat dibangun dan berfungsi lebih maksimal.

DAFTAR PUSTAKA

[1] I. Mawanta, T. S. Gunawan, and W. Wanayumini, "Uji Kemiripan Kalimat Judul Tugas Akhir dengan Metode Cosine Similarity dan Pembobotan TF-IDF," *J. Media Inform. Budidarma*, vol. 5, no. 2, p. 726, 2021, doi: 10.30865/mib.v5i2.2935.

[2] D. A. R. Ariantini, A. S. M. Lumenta, and A. Jacobus, "Pengukuran Kemiripan Dokumen Teks Bahasa Indonesia Menggunakan Metode Cosine Similarity," *J. Tek. Inform.*, vol. 9, no. 1, pp. 1–8, 2016, doi: 10.35793/jti.9.1.2016.13752.

[3] K. S. Nugroho, "Dasar Text Preprocessing dengan Python," 2019. https://ksnugroho.medium.com/dasar-text-preprocessing-dengan-python-a4fa52608ffe (accessed Feb. 07, 2022).

[4] O. R. Hartono, "Indonesian Stoplist," 2016. https://www.kaggle.com/oswinrh/indonesian-stoplist/version/1 (accessed Feb. 07, 2022).

[5] N. Alamsyah, "Deteksi Plagiarisme Tingkat Kemiripan Judul Skripsi Dengan Algoritma Winnowing," *Technol. J. Ilm.*, vol. 8, no. 4, p. 205, 2017, doi: 10.31602/tji.v8i4.1119.

[6] H. Prasetyo, "Perbedaan Cosine Similarity dan Cosine Distance." https://hendroprasetyo.com/perbedaan-cosine-similarity-dan-cosine-distance/#.YgDb4bpBzIW (accessed Feb. 07, 2022).

[7] D. Suhartono, "Natural Language Processing." https://socs.binus.ac.id/2013/06/22/natural-language-processing/ (accessed Feb. 07, 2022).

[8] E. L. Steven Bird, Ewan Klien, *Natural Language Processing with Python*, First Edit. Sebastopol, CA 95472.: O'reilly Media Inc, 2009.

[9] E. SATRIYANTO, “Pengolahan Bahasa Alami.” http://kangedi.lecturer.pens.ac.id/materi kuliah/Kecerdasan Buatan/Bab 5 Natural Language Processing.pdf (accessed Feb. 08, 2022).

[10] M. A. Salim and Y. Anistyasari, “Pengembangan Aplikasi Penilaian Ujian Essay Berbasis Online Menggunakan Algoritma Nazief Dan Adriani Dengan Metode Cosine Mohammad Agus Salim Yeni Anistyasari Abstrak,” *IT-Edu J. Inf. Technol. Educ.*, vol. 02, no. 1, pp. 126–135, 2017.

[11] M. M. umilasari Syabani reni, “Penerapan Metode Cosine Similarity dan Pembobotan TF/IDF pada Sistem Klasifikasi Sinopsis Buku di Perpustakaan Kejaksaan Negeri Jember,” *JUSTINDO (Jurnal Sist. dan Teknol. Inf. Indones.*, no. Vol 3, No 1 (2018): JUSTINDO, pp. 31–42, 2018, [Online]. Available: http://jurnal.unmuhjember.ac.id/index.php/JUSTINDO/article/view/2345.

[12] A. Librian, “High quality stemmer library for Indonesian Language (Bahasa),” 2017. https://github.com/sastrawi/ (accessed Feb. 08, 2022).

[13] R. P. Pratama, M. Faisal, and A. Hanani, “Deteksi Plagiarisme pada Dokumen Jurnal Menggunakan Metode Cosine Similarity,” *SMARTICS J.*, vol. 5, no. 1, pp. 22–26, 2019, doi: 10.21067/smartics.v5i1.2848.

[14] R. Samuel, R. Natan, and U. Syafiqoh, “Penerapan Cosine Similarity dan K-Nearest Neighbor (K-NN) pada Klasifikasi dan Pencarian Buku,” *J. Big Data Anal. Artif. Intell.*, vol. 1, no. 1, pp. 9–14, 2018.

[15] E. L. Amalia, A. J. Jumadi, I. A. Mashudi, and D. W. Wibowo, “Analisis Metode Cosine Similarity Pada Aplikasi Ujian Online Otomatis (Studi Kasus JTI POLINEMA),” *J. Teknol. Inf. dan Ilmu Komput.*, vol. 8, no. 2, p. 343, 2021, doi: 10.25126/jtiik.2021824356.

[16] Z. Efendi and M. Mustakim, “Text Mining Classification sebagai Rekomendasi Dosen Pembimbing Tugas Akhir Program Studi Sistem Informasi,” *Semin. Nas. Teknol. Inf. Komun. dan Ind.*, vol. 0, no. 0, pp. 235–242, 2017, [Online]. Available: http://ejournal.uin-suska.ac.id/index.php/SNTIKI/article/view/3273.

[17] Maskur and F. R. Andriansyah, “Implementasi Web Semantik Untuk Aplikasi Pencarian,” *J. Ilm. NERO*, vol. 2, no. 1, pp. 11–18, 2015.

[18] Sukajati, “Pembelajaran Operasi Penjumlahan Pecahan di SD Menggunakan Berbagai Media,” *Yogyakarta*, p. 52, 2008, [Online]. Available: http://repositori.kemdikbud.go.id/685/1/4-pecahan-sukayati.pdf.